四种 GPU 同期测试横向对比

H20 / H200 / RTX PRO 6000 / Thor

测试时间范围：2026-10-15 至 2026-10-19；报告整理：2026-10-21。仅使用以下四次完整单卡运行，每卡 54 档，共 216 档。

标识	实际型号	唯一运行来源
H20	NVIDIA H20-3e	shape_20261015_172145_h20
H200	NVIDIA H200	shape_20261016_035008_h200
6000	NVIDIA RTX PRO 6000 Blackwell Server Edition	shape_20261017_134318_6000d
Thor	NVIDIA Thor	shape_20261019_113407_thor

单卡；Qwen3-8B-FP8；decoder block 0–23，共 24 层；context_length=81920；SGLang 0.5.19；PyTorch 2.13.0+cu130；mem_fraction_static=0.75。进程内 Engine 直接提交 token IDs，max_new_tokens=1，prefill 完成即结束。

结论

统一固定 prefill=4096、按完整耗时计算：短请求 H200 约为 H20 的 4.1–4.2 倍，6000 多并发平台约为 H20 的 1.9 倍，H20 约为 Thor 的 3.7–3.8 倍；H200 约为 Thor 的 15–16 倍。长请求的排序一致。

缓存场景需要额外看并发：6000 在 C=16 已显著退化，Thor 在该档也有减弱；H20/H200 在 C=32 才出现明显退化。提高并发通常主要增加排队，不能把原报告高并发窗口峰值直接视为稳定容量。

可比性与限制

四组采样规则、seed、并发档位和计时设置一致。216 份 CSV 的原始吞吐、p90 与命中率已全部复现；四组共有 3,372 个（形状、item、segment）键，输入 token 长度一致。不同卡完成的请求数量及样本组成仍有差异；未对四组完整样本池和模型权重重新做字节级哈希校验。

H20/H200 日志记录 DeepGEMM；Thor 使用 Triton FP8 GEMM 与 FlashInfer，120W 系统模式。6000 本次归档未完整记录 resolved 后端。倍率反映完整硬件与软件组合，不等同于纯硬件架构倍率。

每档仅一次运行，无独立重复实验或置信区间；长请求低并发样本较少，分位延迟应作近似参考。结果不代表完整 36 层模型、持续 decode、HTTP 与分词端到端性能，也不能直接推导每瓦或每元性能。

统计方法与代表性数据

原始窗口吞吐：把每个请求的 token 按其请求生命周期与发请求窗口的重叠比例分摊，再除以窗口时长。完整耗时吞吐：全部完成请求的 token 总数 ÷ 最后一个请求完成时刻（计时从测量阶段 t=0 开始，包含在途排空，不包含引擎加载和预热）。两者均由客户端记录复算，不是引擎内部的逐 token 执行计数。

横向吞吐默认采用完整耗时口径；原始窗口值在各卡报告中保留。延迟与命中率使用所有完成请求，与原汇总一致。此口径用于检查窗口估算的敏感性，也不是独立的稳态测量。

固定 4096、同为并发 C=8

指标	H20	H200	6000	Thor
短请求 计算 tok/s	20,811	87,479	40,076	5,518
短请求 p90 秒	1.58	0.38	0.83	5.96
长请求 计算 tok/s	7,238	31,250	13,888	1,985
长请求 p90 秒	75.00	17.90	39.56	267.97
分段无缓存 计算 tok/s	9,216	37,911	18,104	2,492
分段有缓存 服务 tok/s	18,738	80,064	36,736	5,201
分段有缓存 p90 秒	24.60	5.86	12.52	87.53

短请求高并发窗口值的敏感性

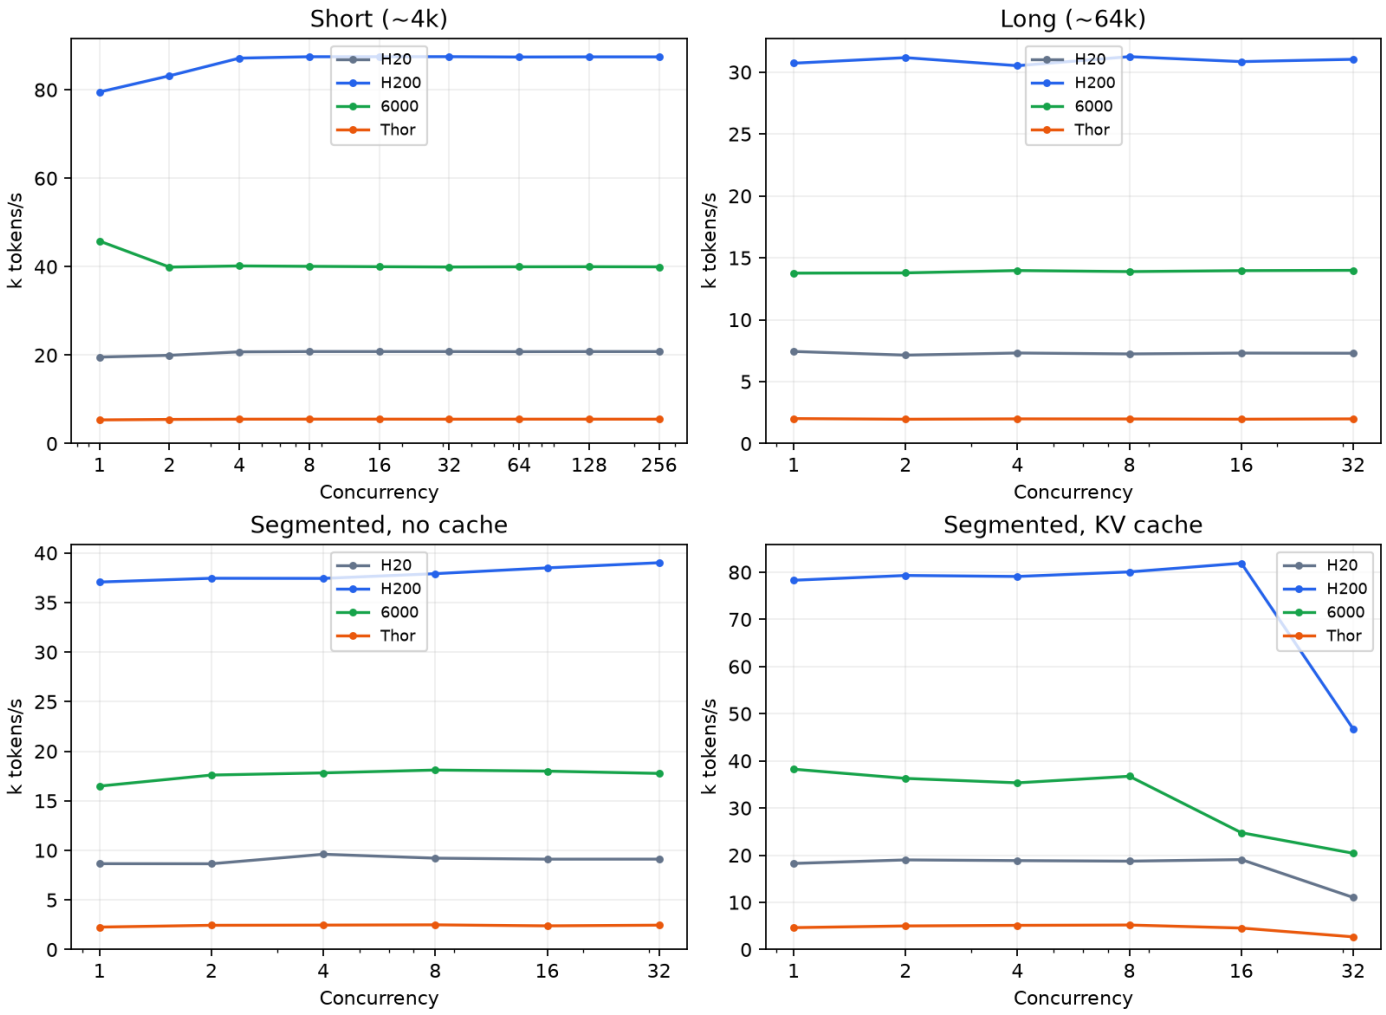
C=256；tok/s	H20	H200	6000	Thor
原始窗口	23,392	95,865	44,883	6,188
完整耗时	20,802	87,447	39,964	5,511

窗口指标按请求生命周期均匀分摊 token，但请求生命周期包含排队。当收尾阶段较长时，会出现明显差异。完整耗时结果显示各卡短请求在较低并发已接近平台。

6000 短请求 C=1 的例外

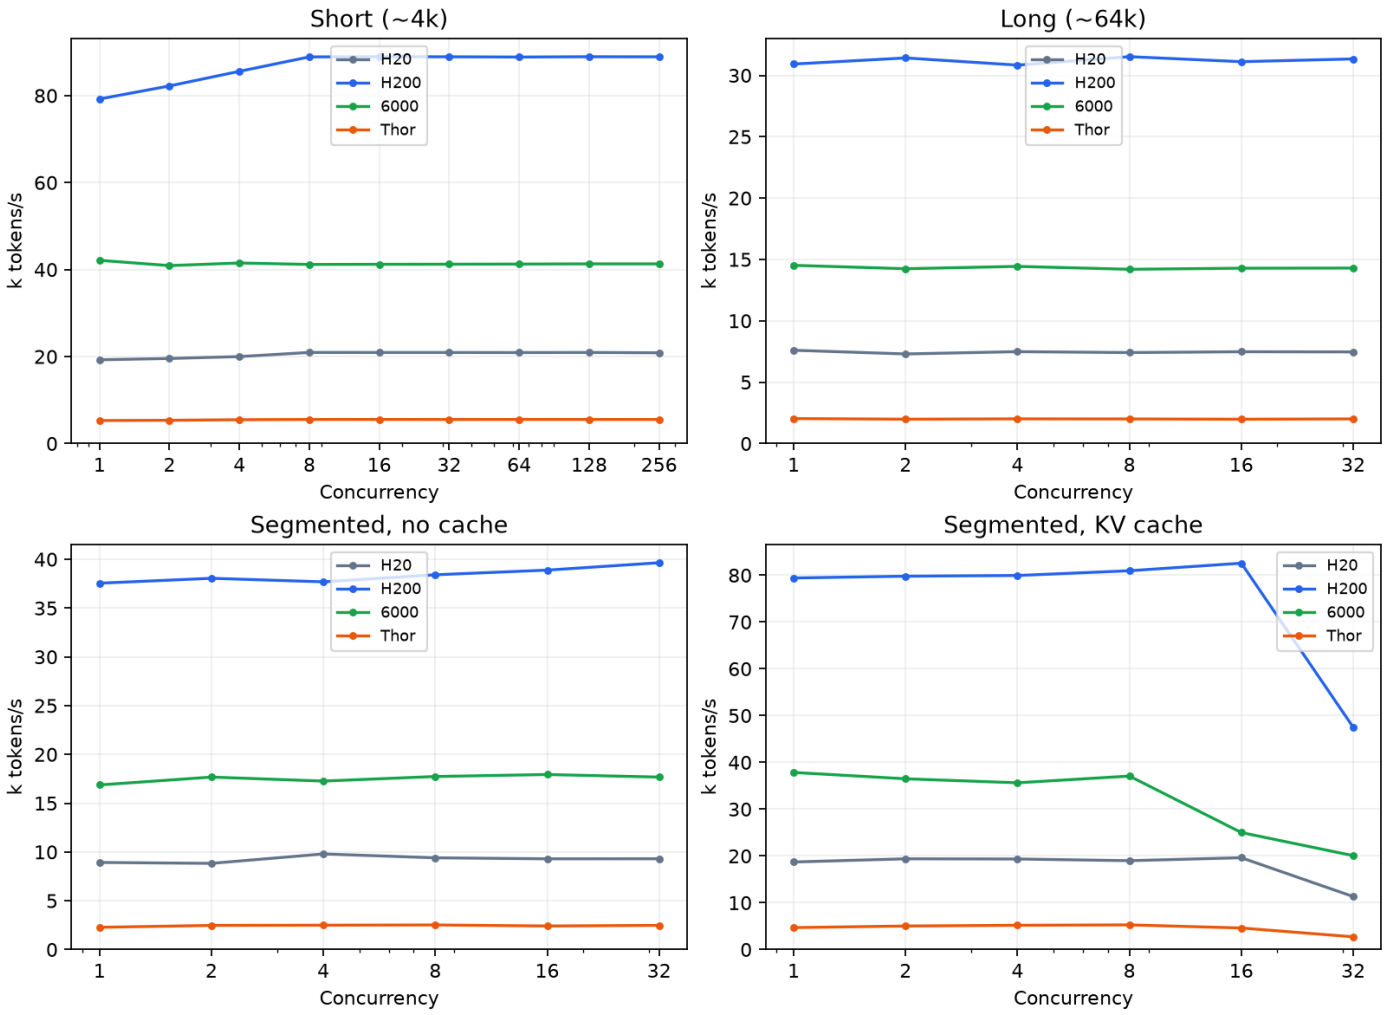
6000 的固定 4096 / default 两组在 C=1 的原报告吞吐分别约 45.8k / 42.1k tok/s，均高于其 C=2；逐请求复算仍保留该现象。缺少重复运行及频率、实测功耗记录，原因未定，不把单个峰值直接作为多并发容量。

吞吐曲线：prefill=4096



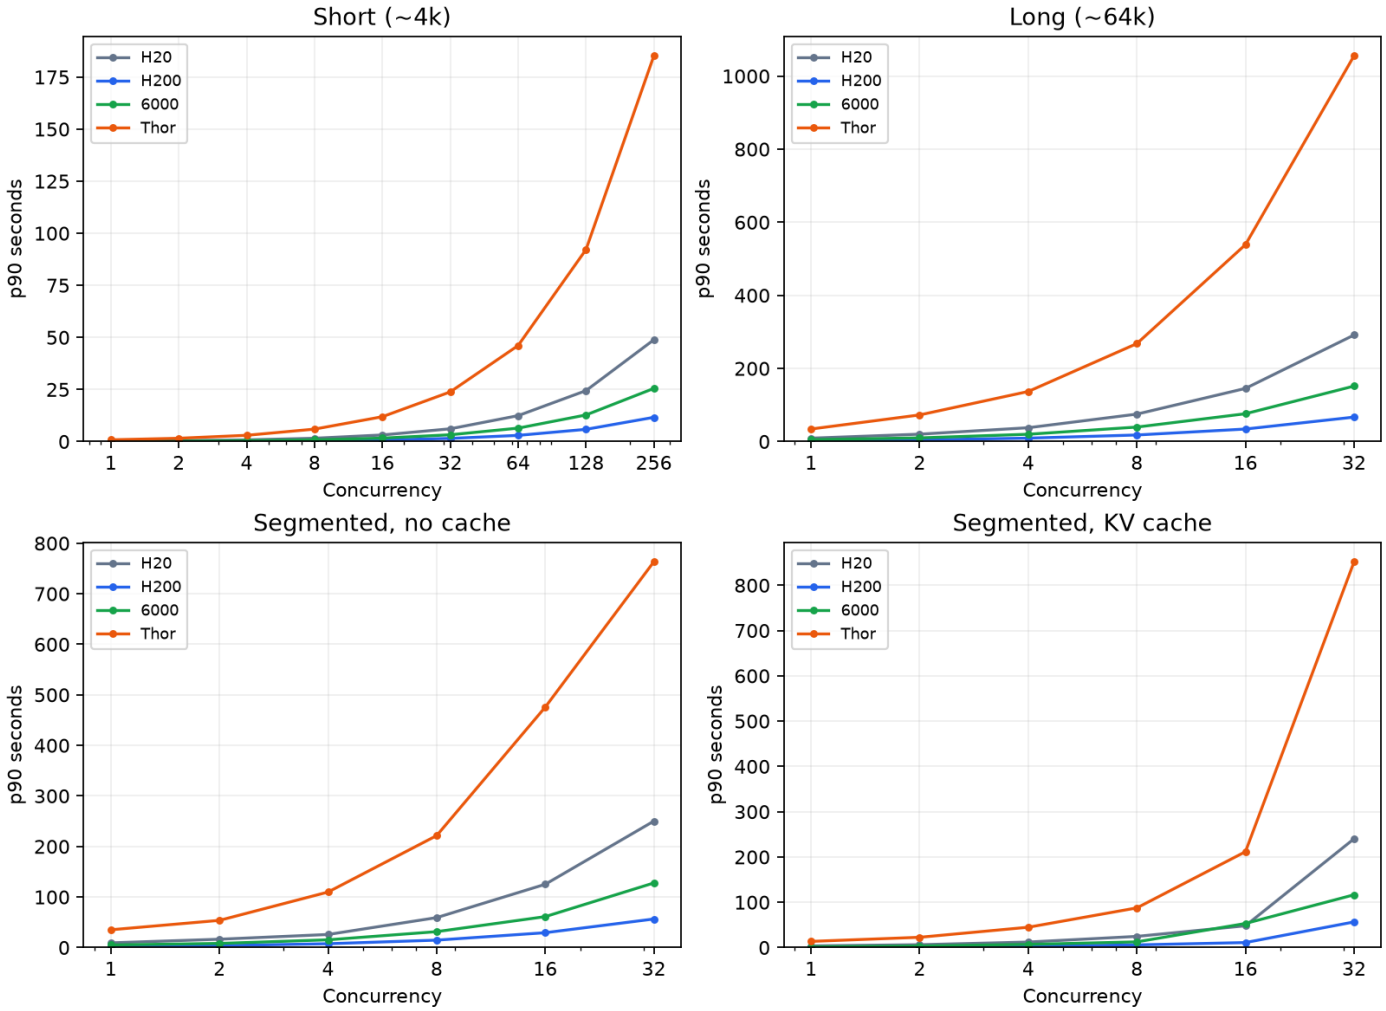
前三个面板为完整耗时计算吞吐；分段缓存面板为完整耗时服务吞吐。default 是各卡自动解析配置，不能假设所有 resolved chunk / max_prefill 参数完全一致，因此主倍率采用固定 4096。

吞吐曲线：prefill=default



前三个面板为完整耗时计算吞吐；分段缓存面板为完整耗时服务吞吐。default 是各卡自动解析配置，不能假设所有 resolved chunk / max_prefill 参数完全一致，因此主倍率采用固定 4096。

延迟曲线：prefill=4096



客户端 p90，含排队；分段形状为每段延迟。高并发长请求可能在停止发新请求后继续排空很长时间。

完整耗时计算吞吐倍率范围

形状	H200/H20	6000/H20	H20/Thor	H200/Thor
short	4.07–4.21×	1.92–2.34×	3.66–3.78×	14.88–15.89×
long	4.13–4.37×	1.85–1.93×	3.64–3.72×	15.24–15.87×
long_seg_nocache	3.90–4.33×	1.85–2.03×	3.54–3.90×	15.18–16.37×
long_seg_cache	3.95–4.24×	1.83–2.07×	3.46–3.76×	14.23–15.91×

范围覆盖该形状全部已测并发，逐并发配对；6000 的 C=1 例外也包含在范围内。缓存计算吞吐扣除命中 token，不能替代服务吞吐。

分段 KV 缓存：收益与退化

固定 prefill=4096。每条轨迹有四个累积前缀；服务吞吐包含被缓存复用的输入。缓存命中比例与完成样本组成有关。

GPU	轨迹 C	命中率	完整服务 tok/s	每段 p90 秒
H20	8	60.4%	18,738	24.60
H20	16	60.8%	19,070	48.05
H20	32	28.7%	11,043	240.22
H200	8	63.3%	80,064	5.86
H200	16	62.5%	81,910	10.98
H200	32	28.7%	46,753	56.56
6000	8	63.0%	36,736	12.52
6000	16	41.1%	24,776	53.12
6000	32	20.5%	20,409	116.49
Thor	8	60.8%	5,201	87.53
Thor	16	56.4%	4,553	211.63
Thor	32	22.0%	2,688	851.89

6000 在 C=16 的服务吞吐优势明显收窄，p90 已高于 H20；Thor 在 C=16 命中率下降，C=32 进一步退化。H20/H200 在 C=32 命中率都降至约 29%，服务吞吐明显回落。

前缀保留的逐请求证据

GPU	C=8 末段完整复用	C=16 末段完整复用	C=32 末段完整复用
H20	100.0%	100.0%	0.0%
H200	100.0%	100.0%	0.0%
6000	100.0%	6.2%	0.0%
Thor	100.0%	68.8%	0.0%

“完整复用”为末段请求 cached_tokens ≥ 同轨迹上一段输入长度的请求比例。这直接说明前缀保留情况，结合容量差异与 KV 逐出相符；本报告不引用后续诊断实验来断言本次测试中的逐出次数。

满足延迟目标的已测并发

固定 prefill=4096；0 表示 C=1 也未达标。仅列已测档位中最大 C，不作未测并发的插值或容量保证。

形状	p90 上限	H20	H200	6000	Thor
short	0.25s	1	4	2	0
short	0.5s	2	8	4	0
short	1s	4	16	8	1
short	2s	8	32	16	2
long	10s	1	4	1	0
long	20s	1	8	4	0
long	30s	2	8	4	0
long	60s	4	16	8	1
long_seg_nocache	10s	1	4	2	0
long_seg_nocache	20s	2	8	4	0
long_seg_nocache	30s	4	16	4	0
long_seg_nocache	60s	8	32	8	2
long_seg_cache	10s	2	8	4	0
long_seg_cache	20s	4	16	8	1
long_seg_cache	30s	8	16	8	2
long_seg_cache	60s	16	32	16	4

短请求 p90≤1 秒：H20 / H200 / 6000 / Thor 分别支持 4 / 16 / 8 / 1 个已测并发。64k 长请求 p90≤60 秒分别为 4 / 16 / 8 / 1。分段轨迹的并发和每段延迟应配套解释。

逐档明细：prefill=4096

每格：完整耗时吞吐（千 tok/s） / p90 秒；分段缓存采用服务吞吐，其余采用计算吞吐。

形状	C	H20	H200	6000	Thor
短 4k	1	19.55 / 0.22	79.51 / 0.06	45.79 / 0.10	5.34 / 0.83
短 4k	2	19.95 / 0.43	83.17 / 0.11	39.91 / 0.22	5.46 / 1.57
短 4k	4	20.73 / 0.79	87.16 / 0.19	40.17 / 0.41	5.51 / 2.99
短 4k	8	20.81 / 1.58	87.48 / 0.38	40.08 / 0.83	5.52 / 5.96
短 4k	16	20.81 / 3.16	87.48 / 0.75	40.00 / 1.64	5.52 / 11.91
短 4k	32	20.81 / 6.11	87.49 / 1.50	39.93 / 3.25	5.51 / 23.83
短 4k	64	20.78 / 12.43	87.42 / 2.95	39.97 / 6.43	5.51 / 46.08
短 4k	128	20.80 / 24.44	87.45 / 5.86	39.99 / 12.76	5.51 / 92.14
短 4k	256	20.80 / 48.85	87.45 / 11.62	39.96 / 25.50	5.51 / 185.20
长 64k	1	7.44 / 9.21	30.72 / 2.40	13.76 / 5.25	2.02 / 34.26
长 64k	2	7.14 / 20.16	31.17 / 4.50	13.79 / 10.01	1.96 / 72.81
长 64k	4	7.31 / 37.78	30.52 / 9.29	13.97 / 19.93	1.99 / 136.94
长 64k	8	7.24 / 75.00	31.25 / 17.90	13.89 / 39.56	1.98 / 267.97
长 64k	16	7.31 / 145.36	30.85 / 34.20	13.96 / 76.05	1.97 / 538.78
长 64k	32	7.29 / 291.48	31.04 / 66.84	13.99 / 151.72	1.99 / 1055.53
分段无缓存	1	8.66 / 9.26	37.07 / 2.01	16.48 / 5.08	2.26 / 35.14
分段无缓存	2	8.65 / 16.44	37.45 / 3.81	17.60 / 8.16	2.45 / 53.75
分段无缓存	4	9.61 / 25.83	37.43 / 7.55	17.82 / 15.27	2.47 / 109.79
分段无缓存	8	9.22 / 59.19	37.91 / 14.64	18.10 / 31.42	2.49 / 221.46
分段无缓存	16	9.12 / 125.15	38.50 / 29.34	17.99 / 61.15	2.39 / 475.71
分段无缓存	32	9.12 / 250.15	39.01 / 56.47	17.76 / 127.79	2.46 / 763.35
分段有缓存	1	18.25 / 3.67	78.29 / 0.84	38.24 / 1.64	4.64 / 13.57
分段有缓存	2	19.00 / 6.25	79.31 / 1.51	36.29 / 3.34	5.00 / 22.64
分段有缓存	4	18.85 / 12.11	79.10 / 2.93	35.35 / 6.95	5.13 / 44.82
分段有缓存	8	18.74 / 24.60	80.06 / 5.86	36.74 / 12.52	5.20 / 87.53
分段有缓存	16	19.07 / 48.05	81.91 / 10.98	24.78 / 53.12	4.55 / 211.63
分段有缓存	32	11.04 / 240.22	46.75 / 56.56	20.41 / 116.49	2.69 / 851.89

逐档明细：prefill=default

每格：完整耗时吞吐（千 tok/s） / p90 秒；分段缓存采用服务吞吐，其余采用计算吞吐。

形状	C	H20	H200	6000	Thor
短 4k	1	19.26 / 0.23	79.22 / 0.06	42.13 / 0.11	5.29 / 0.85
短 4k	2	19.56 / 0.43	82.23 / 0.10	40.91 / 0.21	5.34 / 1.63
短 4k	4	19.99 / 0.81	85.58 / 0.19	41.51 / 0.40	5.47 / 3.10
短 4k	8	20.95 / 1.57	88.90 / 0.37	41.18 / 0.80	5.53 / 5.94
短 4k	16	20.93 / 3.14	88.94 / 0.74	41.22 / 1.60	5.54 / 11.87
短 4k	32	20.93 / 6.26	88.92 / 1.48	41.23 / 3.19	5.53 / 23.74
短 4k	64	20.92 / 12.53	88.87 / 2.95	41.27 / 6.19	5.53 / 45.93
短 4k	128	20.94 / 24.27	88.94 / 5.72	41.31 / 12.31	5.53 / 91.85
短 4k	256	20.87 / 48.70	88.92 / 11.44	41.31 / 24.62	5.53 / 185.28
长 64k	1	7.60 / 9.00	30.92 / 2.39	14.52 / 4.98	2.03 / 33.93
长 64k	2	7.30 / 19.71	31.42 / 4.51	14.24 / 9.74	1.98 / 71.15
长 64k	4	7.49 / 36.93	30.83 / 9.14	14.43 / 19.35	2.01 / 135.91
长 64k	8	7.41 / 73.22	31.52 / 17.66	14.20 / 38.72	2.00 / 265.58
长 64k	16	7.48 / 142.03	31.11 / 33.91	14.29 / 74.21	1.98 / 534.49
长 64k	32	7.47 / 284.21	31.34 / 66.17	14.30 / 148.28	2.01 / 1046.95
分段无缓存	1	8.92 / 8.85	37.55 / 1.98	16.87 / 4.98	2.28 / 34.82
分段无缓存	2	8.83 / 16.07	38.05 / 3.91	17.68 / 7.88	2.47 / 53.26
分段无缓存	4	9.80 / 25.31	37.69 / 7.48	17.27 / 15.47	2.50 / 108.44
分段无缓存	8	9.40 / 57.91	38.41 / 14.29	17.74 / 31.49	2.52 / 217.81
分段无缓存	16	9.30 / 122.19	38.89 / 29.18	17.94 / 61.02	2.41 / 471.62
分段无缓存	32	9.30 / 244.08	39.64 / 55.39	17.67 / 128.17	2.48 / 757.58
分段有缓存	1	18.71 / 3.55	79.40 / 0.83	37.85 / 1.65	4.69 / 13.45
分段有缓存	2	19.39 / 5.93	79.78 / 1.63	36.49 / 3.30	5.03 / 21.99
分段有缓存	4	19.35 / 12.20	79.93 / 2.98	35.64 / 6.76	5.18 / 44.50
分段有缓存	8	18.99 / 24.83	80.95 / 5.86	37.07 / 12.74	5.27 / 87.17
分段有缓存	16	19.62 / 46.53	82.56 / 11.13	25.00 / 52.25	4.60 / 206.52
分段有缓存	32	11.32 / 233.61	47.49 / 55.43	20.06 / 117.83	2.72 / 841.24