H20 请求形状与并发测试报告

NVIDIA H20-3e

测试日期：2026-10-15；54/54 档；完成请求合计 10,410。

单卡；Qwen3-8B-FP8；decoder block 0–23，共 24 层；context_length=81920；SGLang 0.5.19；PyTorch 2.13.0+cu130；mem_fraction_static=0.75。进程内 Engine 直接提交 token IDs，max_new_tokens=1，prefill 完成即结束。

来源与可比范围

唯一来源运行：shape_20261015_172145_h20

本报告只使用该次完整测试的 summary.jsonl、逐请求 CSV、config.yaml、sampling_config.json、env.txt / serve.log；不混入其他测试或后续 KV 诊断。所有 54 档计算/服务吞吐、命中率和 p90 均已由原始请求 CSV 复算，与原汇总一致。

负载与统计口径

闭环并发：普通形状为 C 个在途请求；分段形状为 C 条轨迹，每条轨迹的四个累积前缀顺序发送。每档至少 60 秒且完成 4×C 请求；达到 900 秒时停止发新请求，再排空在途请求。prefill=4096 同时设置 chunked_prefill_size 和 max_prefill_tokens；default 由引擎解析。

原始窗口吞吐：把每个请求的 token 按其请求生命周期与发请求窗口的重叠比例分摊，再除以窗口时长。完整耗时吞吐：全部完成请求的 token 总数 ÷ 最后一个请求完成时刻（计时从测量阶段 t=0 开始，包含在途排空，不包含引擎加载和预热）。两者均由客户端记录复算，不是引擎内部的逐 token 执行计数。

计算吞吐只计输入减缓存命中后的 token；服务吞吐计全部输入 token。延迟包含客户端提交至完成期间的排队与计算；分段形状的延迟是每段延迟。

每档仅一次运行，无独立重复实验或置信区间；长请求低并发样本较少，分位延迟应作近似参考。结果不代表完整 36 层模型、持续 decode、HTTP 与分词端到端性能，也不能直接推导每瓦或每元性能。

日志记录 DeepGEMM 预热。H20 基线报告记录 KV 池约 106.8 万 token。

短请求（约 4k）

吞吐单位 tok/s；延迟单位秒。窗口计算为原报告数值；完整计算 / 完整服务包含排空阶段。缓存命中率按全部完成请求 token 统计。

prefill size = 4096

并发 C	窗口计算	完整计算	完整服务	命中率	p90 秒	请求数
1	19,549	19,550	19,550	0.0%	0.219	296
2	19,984	19,953	19,953	0.0%	0.434	304
4	20,797	20,733	20,733	0.0%	0.790	318
8	21,030	20,811	20,811	0.0%	1.579	325
16	21,279	20,809	20,809	0.0%	3.155	332
32	21,816	20,807	20,807	0.0%	6.111	348
64	22,844	20,779	20,779	0.0%	12.426	377
128	23,402	20,803	20,803	0.0%	24.436	640
256	23,392	20,802	20,802	0.0%	48.855	1280

prefill size = default

并发 C	窗口计算	完整计算	完整服务	命中率	p90 秒	请求数
1	19,259	19,260	19,260	0.0%	0.231	292
2	19,590	19,556	19,556	0.0%	0.428	298
4	20,072	19,990	19,990	0.0%	0.815	308
8	21,106	20,946	20,946	0.0%	1.569	327
16	21,381	20,932	20,932	0.0%	3.136	332
32	21,902	20,934	20,934	0.0%	6.265	348
64	22,928	20,917	20,917	0.0%	12.534	377
128	23,526	20,937	20,937	0.0%	24.267	640
256	23,457	20,870	20,870	0.0%	48.696	1280

C=256 原窗口吞吐为 23,392，完整耗时吞吐为 20,802。高并发窗口值可能受按生命周期分摊 token 的估算影响，不能直接当作稳定容量。

长请求（约 64k，一次性提交）

吞吐单位 tok/s；延迟单位秒。窗口计算为原报告数值；完整计算 / 完整服务包含排空阶段。缓存命中率按全部完成请求 token 统计。

prefill size = 4096

并发 C	窗口计算	完整计算	完整服务	命中率	p90 秒	请求数
1	7,387	7,438	7,438	0.0%	9.206	8
2	7,505	7,140	7,140	0.0%	20.156	10
4	8,035	7,313	7,313	0.0%	37.782	20
8	8,127	7,238	7,238	0.0%	75.004	40
16	8,192	7,306	7,306	0.0%	145.364	80
32	8,370	7,294	7,294	0.0%	291.479	132

prefill size = default

并发 C	窗口计算	完整计算	完整服务	命中率	p90 秒	请求数
1	7,559	7,601	7,601	0.0%	9.000	8
2	7,654	7,300	7,300	0.0%	19.712	10
4	8,221	7,486	7,486	0.0%	36.925	20
8	8,316	7,411	7,411	0.0%	73.224	40
16	8,385	7,480	7,480	0.0%	142.034	80
32	8,545	7,466	7,466	0.0%	284.209	135

长轨迹分四段，不复用 KV

吞吐单位 tok/s；延迟单位秒。窗口计算为原报告数值；完整计算 / 完整服务包含排空阶段。缓存命中率按全部完成请求 token 统计。

prefill size = 4096

并发 C	窗口计算	完整计算	完整服务	命中率	p90 秒	请求数
1	8,647	8,661	8,661	0.0%	9.261	13
2	9,616	8,652	8,652	0.0%	16.443	16
4	9,848	9,610	9,610	0.0%	25.831	20
8	9,494	9,216	9,216	0.0%	59.187	40
16	9,422	9,115	9,115	0.0%	125.147	80
32	9,453	9,118	9,118	0.0%	250.149	160

prefill size = default

并发 C	窗口计算	完整计算	完整服务	命中率	p90 秒	请求数
1	8,856	8,925	8,925	0.0%	8.850	14
2	9,759	8,833	8,833	0.0%	16.069	16
4	10,009	9,797	9,797	0.0%	25.307	20
8	9,677	9,402	9,402	0.0%	57.908	40
16	9,613	9,298	9,298	0.0%	122.186	80
32	9,650	9,303	9,303	0.0%	244.079	160

长轨迹分四段，复用 KV

吞吐单位 tok/s；延迟单位秒。窗口计算为原报告数值；完整计算 / 完整服务包含排空阶段。缓存命中率按全部完成请求 token 统计。

prefill size = 4096

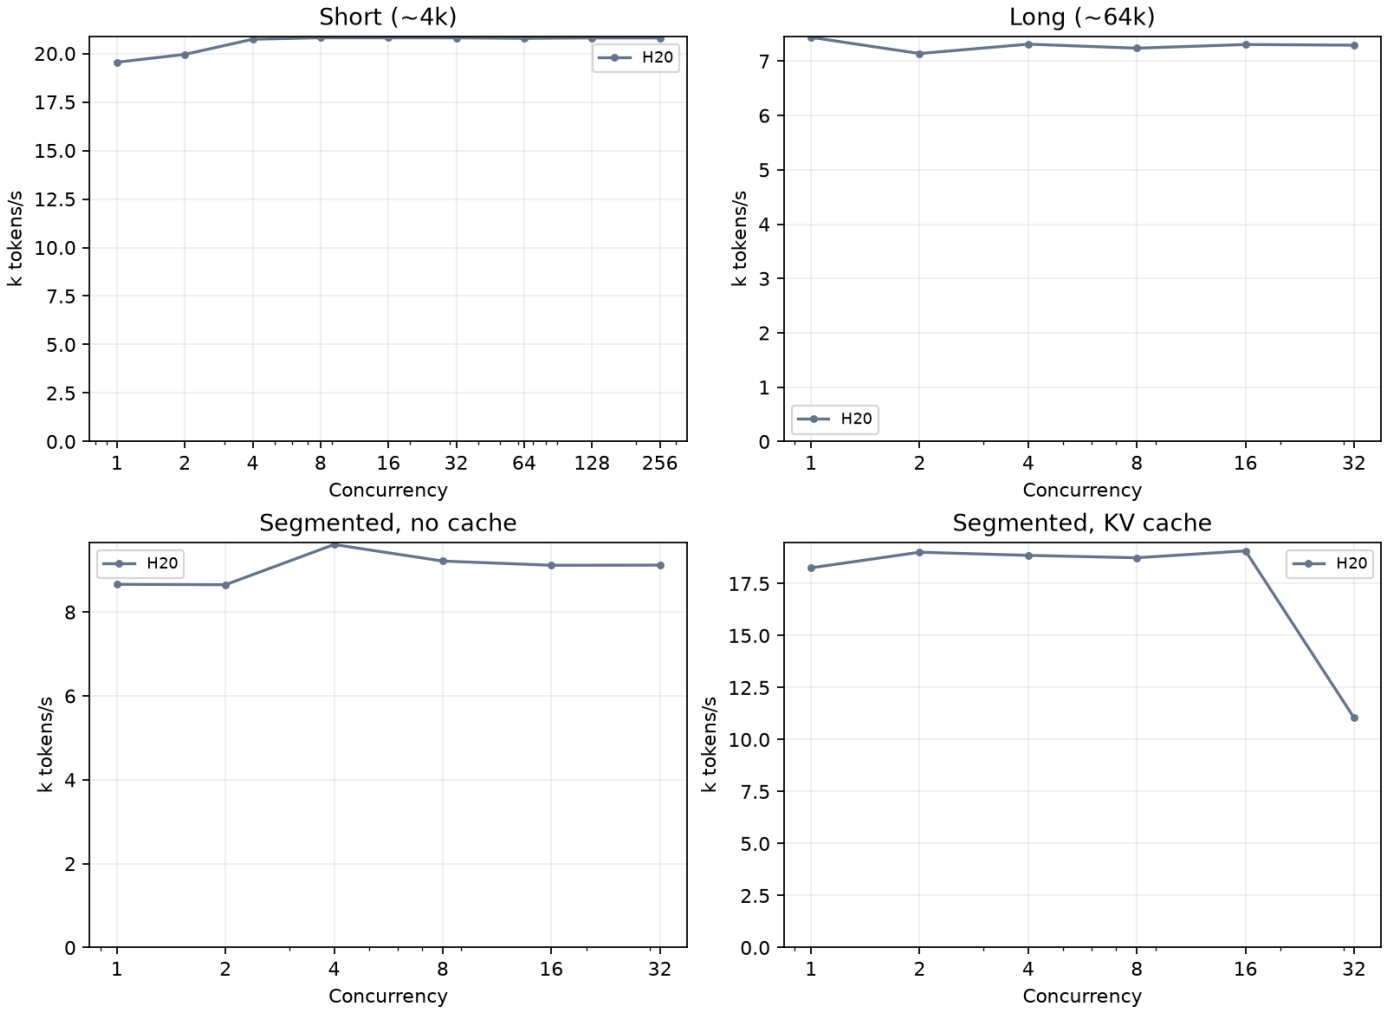
并发 C	窗口计算	完整计算	完整服务	命中率	p90 秒	请求数
1	6,856	6,852	18,254	62.5%	3.674	27
2	7,361	7,056	19,005	62.9%	6.248	32
4	7,608	7,048	18,853	62.6%	12.113	33
8	7,693	7,424	18,738	60.4%	24.604	40
16	7,775	7,475	19,070	60.8%	48.048	80
32	8,141	7,873	11,043	28.7%	240.221	160

prefill size = default

并发 C	窗口计算	完整计算	完整服务	命中率	p90 秒	请求数
1	6,964	6,889	18,709	63.2%	3.549	28
2	7,480	7,198	19,388	62.9%	5.931	32
4	7,694	7,284	19,348	62.4%	12.203	34
8	7,772	7,534	18,986	60.3%	24.825	40
16	7,997	7,686	19,619	60.8%	46.530	80
32	8,329	8,057	11,319	28.8%	233.612	160

固定 4096：C=8 / 16 / 32 命中率分别为 60.4% / 60.8% / 28.7%；完整服务吞吐为 18,738 / 19,070 / 11,043。缓存保留情况改变时应同时看服务吞吐与延迟。

曲线与延迟目标



固定 prefill=4096；完整耗时吞吐。分段缓存面板展示含缓存命中的服务吞吐。

满足 p90 的最大已测并发

0 表示 C=1 也未达标；仅在已测离散档位中选最大值，不代表精确并发极限。

形状	p90 要求	4096 最大 C	default 最大 C
short	⩽ 0.25s	1	1
short	⩽ 0.5s	2	2
short	⩽ 1s	4	4
short	⩽ 2s	8	8
long	⩽ 10s	1	1
long	⩽ 20s	1	2
long	⩽ 30s	2	2
long	⩽ 60s	4	4
long_seg_nocache	⩽ 10s	1	1
long_seg_nocache	⩽ 20s	2	2
long_seg_nocache	⩽ 30s	4	4
long_seg_nocache	⩽ 60s	8	8
long_seg_cache	⩽ 10s	2	2
long_seg_cache	⩽ 20s	4	4
long_seg_cache	⩽ 30s	8	8
long_seg_cache	⩽ 60s	16	16

每档仅一次运行，无独立重复实验或置信区间；长请求低并发样本较少，分位延迟应作近似参考。结果不代表完整 36 层模型、持续 decode、HTTP 与分词端到端性能，也不能直接推导每瓦或每元性能。