6000 请求形状与并发测试报告

NVIDIA RTX PRO 6000 Blackwell Server Edition

测试日期：2026-10-17；54/54 档；完成请求合计 15,369。

单卡；Qwen3-8B-FP8；decoder block 0–23，共 24 层；context_length=81920；SGLang 0.5.19；PyTorch 2.13.0+cu130；mem_fraction_static=0.75。进程内 Engine 直接提交 token IDs，max_new_tokens=1，prefill 完成即结束。

来源与可比范围

唯一来源运行：shape_20261017_134318_6000d

本报告只使用该次完整测试的 summary.jsonl、逐请求 CSV、config.yaml、sampling_config.json、env.txt / serve.log；不混入其他测试或后续 KV 诊断。所有 54 档计算/服务吞吐、命中率和 p90 均已由原始请求 CSV 复算，与原汇总一致。

负载与统计口径

闭环并发：普通形状为 C 个在途请求；分段形状为 C 条轨迹，每条轨迹的四个累积前缀顺序发送。每档至少 60 秒且完成 4×C 请求；达到 900 秒时停止发新请求，再排空在途请求。prefill=4096 同时设置 chunked_prefill_size 和 max_prefill_tokens；default 由引擎解析。

原始窗口吞吐：把每个请求的 token 按其请求生命周期与发请求窗口的重叠比例分摊，再除以窗口时长。完整耗时吞吐：全部完成请求的 token 总数 ÷ 最后一个请求完成时刻（计时从测量阶段 t=0 开始，包含在途排空，不包含引擎加载和预热）。两者均由客户端记录复算，不是引擎内部的逐 token 执行计数。

计算吞吐只计输入减缓存命中后的 token；服务吞吐计全部输入 token。延迟包含客户端提交至完成期间的排队与计算；分段形状的延迟是每段延迟。

每档仅一次运行，无独立重复实验或置信区间；长请求低并发样本较少，分位延迟应作近似参考。结果不代表完整 36 层模型、持续 decode、HTTP 与分词端到端性能，也不能直接推导每瓦或每元性能。

环境记录显存 97,887 MiB，功率上限 600W；功率上限不等于实测功耗。本次归档未完整记录 resolved FP8 / attention 后端与 KV token 容量，不据此推断后端或精确容量。

短请求（约 4k）

吞吐单位 tok/s；延迟单位秒。窗口计算为原报告数值；完整计算 / 完整服务包含排空阶段。缓存命中率按全部完成请求 token 统计。

prefill size = 4096

并发 C	窗口计算	完整计算	完整服务	命中率	p90 秒	请求数
1	45,790	45,790	45,790	0.0%	0.098	694
2	39,944	39,908	39,908	0.0%	0.220	609
4	40,256	40,168	40,168	0.0%	0.414	615
8	40,277	40,076	40,076	0.0%	0.825	613
16	40,449	39,996	39,996	0.0%	1.645	623
32	40,917	39,927	39,927	0.0%	3.246	638
64	42,004	39,973	39,973	0.0%	6.427	668
128	44,134	39,992	39,992	0.0%	12.758	734
256	44,883	39,964	39,964	0.0%	25.500	1281

prefill size = default

并发 C	窗口计算	完整计算	完整服务	命中率	p90 秒	请求数
1	42,128	42,127	42,127	0.0%	0.108	639
2	40,942	40,911	40,911	0.0%	0.205	624
4	41,591	41,514	41,514	0.0%	0.401	636
8	41,338	41,178	41,178	0.0%	0.802	629
16	41,635	41,216	41,216	0.0%	1.601	641
32	42,195	41,234	41,234	0.0%	3.190	656
64	43,267	41,267	41,267	0.0%	6.187	686
128	45,412	41,311	41,311	0.0%	12.315	754
256	46,384	41,311	41,311	0.0%	24.622	1283

C=256 原窗口吞吐为 44,883，完整耗时吞吐为 39,964。高并发窗口值可能受按生命周期分摊 token 的估算影响，不能直接当作稳定容量。

长请求（约 64k，一次性提交）

吞吐单位 tok/s；延迟单位秒。窗口计算为原报告数值；完整计算 / 完整服务包含排空阶段。缓存命中率按全部完成请求 token 统计。

prefill size = 4096

并发 C	窗口计算	完整计算	完整服务	命中率	p90 秒	请求数
1	13,769	13,763	13,763	0.0%	5.251	13
2	14,289	13,785	13,785	0.0%	10.009	14
4	15,316	13,972	13,972	0.0%	19.930	20
8	15,428	13,888	13,888	0.0%	39.560	40
16	15,629	13,964	13,964	0.0%	76.050	80
32	15,665	13,990	13,990	0.0%	151.722	160

prefill size = default

并发 C	窗口计算	完整计算	完整服务	命中率	p90 秒	请求数
1	14,507	14,521	14,521	0.0%	4.984	14
2	14,776	14,244	14,244	0.0%	9.745	14
4	15,790	14,434	14,434	0.0%	19.351	20
8	15,755	14,198	14,198	0.0%	38.722	40
16	15,985	14,286	14,286	0.0%	74.206	80
32	16,015	14,298	14,298	0.0%	148.277	160

长轨迹分四段，不复用 KV

吞吐单位 tok/s；延迟单位秒。窗口计算为原报告数值；完整计算 / 完整服务包含排空阶段。缓存命中率按全部完成请求 token 统计。

prefill size = 4096

并发 C	窗口计算	完整计算	完整服务	命中率	p90 秒	请求数
1	16,531	16,485	16,485	0.0%	5.080	24
2	17,915	17,599	17,599	0.0%	8.159	30
4	19,667	17,818	17,818	0.0%	15.271	33
8	18,690	18,104	18,104	0.0%	31.423	40
16	18,633	17,994	17,994	0.0%	61.153	80
32	18,395	17,765	17,765	0.0%	127.790	160

prefill size = default

并发 C	窗口计算	完整计算	完整服务	命中率	p90 秒	请求数
1	16,743	16,871	16,871	0.0%	4.983	25
2	18,213	17,675	17,675	0.0%	7.884	31
4	19,343	17,268	17,268	0.0%	15.468	32
8	18,307	17,735	17,735	0.0%	31.493	40
16	18,590	17,939	17,939	0.0%	61.020	80
32	18,320	17,675	17,675	0.0%	128.175	160

长轨迹分四段，复用 KV

吞吐单位 tok/s；延迟单位秒。窗口计算为原报告数值；完整计算 / 完整服务包含排空阶段。缓存命中率按全部完成请求 token 统计。

prefill size = 4096

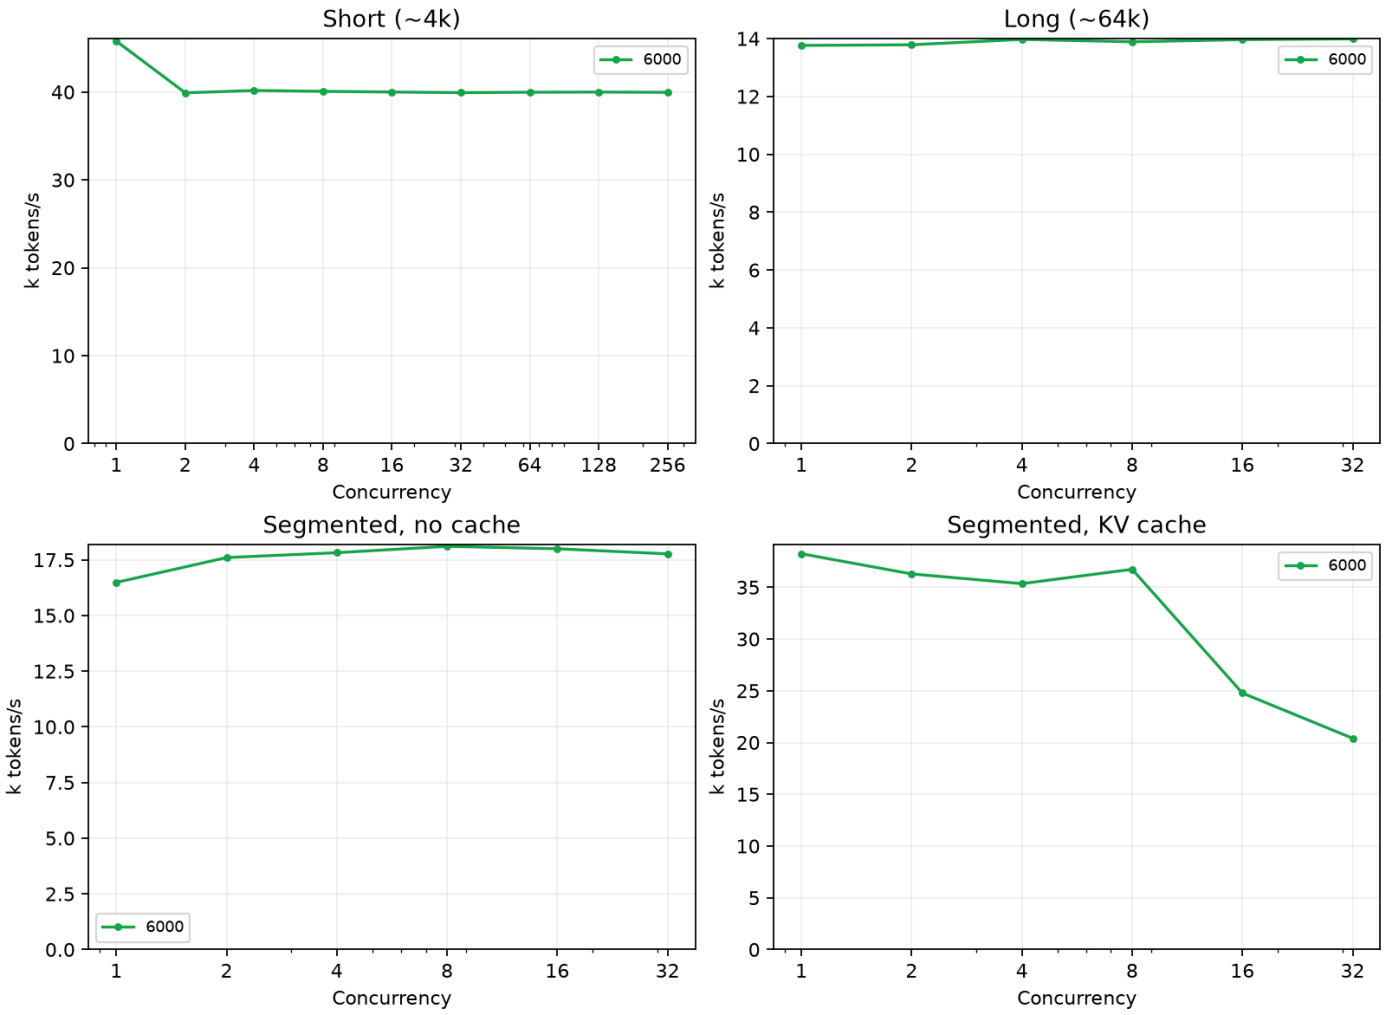
并发 C	窗口计算	完整计算	完整服务	命中率	p90 秒	请求数
1	14,219	14,170	38,236	62.9%	1.639	59
2	13,629	13,354	36,287	63.2%	3.338	56
4	13,675	13,515	35,347	61.8%	6.952	57
8	14,934	13,590	36,736	63.0%	12.521	66
16	15,153	14,603	24,776	41.1%	53.123	80
32	16,759	16,229	20,409	20.5%	116.493	160

prefill size = default

并发 C	窗口计算	完整计算	完整服务	命中率	p90 秒	请求数
1	14,041	14,063	37,846	62.8%	1.648	58
2	13,636	13,482	36,490	63.1%	3.303	57
4	13,794	13,636	35,637	61.7%	6.760	57
8	14,981	13,712	37,067	63.0%	12.741	66
16	15,315	14,748	25,002	41.0%	52.246	80
32	16,489	15,955	20,065	20.5%	117.826	160

固定 4096：C=8 / 16 / 32 命中率分别为 63.0% / 41.1% / 20.5%；完整服务吞吐为 36,736 / 24,776 / 20,409。缓存保留情况改变时应同时看服务吞吐与延迟。

曲线与延迟目标



固定 prefill=4096；完整耗时吞吐。分段缓存面板展示含缓存命中的服务吞吐。

满足 p90 的最大已测并发

0 表示 C=1 也未达标；仅在已测离散档位中选最大值，不代表精确并发极限。

形状	p90 要求	4096 最大 C	default 最大 C
short	⩽ 0.25s	2	2
short	⩽ 0.5s	4	4
short	⩽ 1s	8	8
short	⩽ 2s	16	16
long	⩽ 10s	1	2
long	⩽ 20s	4	4
long	⩽ 30s	4	4
long	⩽ 60s	8	8
long_seg_nocache	⩽ 10s	2	2
long_seg_nocache	⩽ 20s	4	4
long_seg_nocache	⩽ 30s	4	4
long_seg_nocache	⩽ 60s	8	8
long_seg_cache	⩽ 10s	4	4
long_seg_cache	⩽ 20s	8	8
long_seg_cache	⩽ 30s	8	8
long_seg_cache	⩽ 60s	16	16

每档仅一次运行，无独立重复实验或置信区间；长请求低并发样本较少，分位延迟应作近似参考。结果不代表完整 36 层模型、持续 decode、HTTP 与分词端到端性能，也不能直接推导每瓦或每元性能。