Prefill 效率测试报告

配置


```
paths:
  processed_dir: data/processed
  out_dir: results/h20_generation_{timestamp}
processing:
  workers: 64
sampling:
  seed: 20261013
  tokenizer: Qwen/Qwen3-8B-FP8
  max_input_tokens: 131000
  length_buckets:
  - 0
  - 512
  - 1024
  - 2048
  - 4096
  - 8192
  - 16384
  - 32768
  - 65536
  - 131072
  sources:
  - name: wildchat
    format: wildchat
    input: data/WildChat-1M
    num_samples: 90000
    min_tokens: 0
    short_len: 512
    short_keep: 0.1
  - name: swe_rebench
    format: swe_rebench
    input: data/SWE-rebench-openhands-trajectories
    num_samples: 10000
    min_tokens: 0
    short_len: 0
    short_keep: 1.0
runtime:
  python: /mnt/kpfs_qyang/yutongz/CoolWatch/sglang-activation-runtime/.venv/bin/python
  sglang_version: 0.5.21
  allow_version_mismatch: true
  model: /mnt/kpfs_qyang/yutongz/models/Qwen3-8B-FP8
  gpus:
  - 6
  - 7
  tp:
  - 1
  attention_backend:
  - default
  mem_fraction_static: 0.7
  context_length: 131072
  yarn: auto
  batch_tokens: 0
  max_requests: 1000
  extra_server_args: ''
  peak_tflops: 296
  monitor_interval: 0.5
  base_port: 31000
  generation:
    enabled: true
    max_new_tokens: 2048
    default_new_tokens: 256
pipeline:
  confirm: true
  stats_only: false
```

运行环境

```
host: 10-0-2-54
0, NVIDIA H20-3e, 143771 MiB, 580.82.07, 500.00 W
1, NVIDIA H20-3e, 143771 MiB, 580.82.07, 500.00 W
2, NVIDIA H20-3e, 143771 MiB, 580.82.07, 500.00 W
3, NVIDIA H20-3e, 143771 MiB, 580.82.07, 500.00 W
4, NVIDIA H20-3e, 143771 MiB, 580.82.07, 500.00 W
5, NVIDIA H20-3e, 143771 MiB, 580.82.07, 500.00 W
6, NVIDIA H20-3e, 143771 MiB, 580.82.07, 500.00 W
7, NVIDIA H20-3e, 143771 MiB, 580.82.07, 500.00 W
sglang 0.5.19
torch 2.13.0+cu130 cuda 13.0
```

测试数据（下采样后）

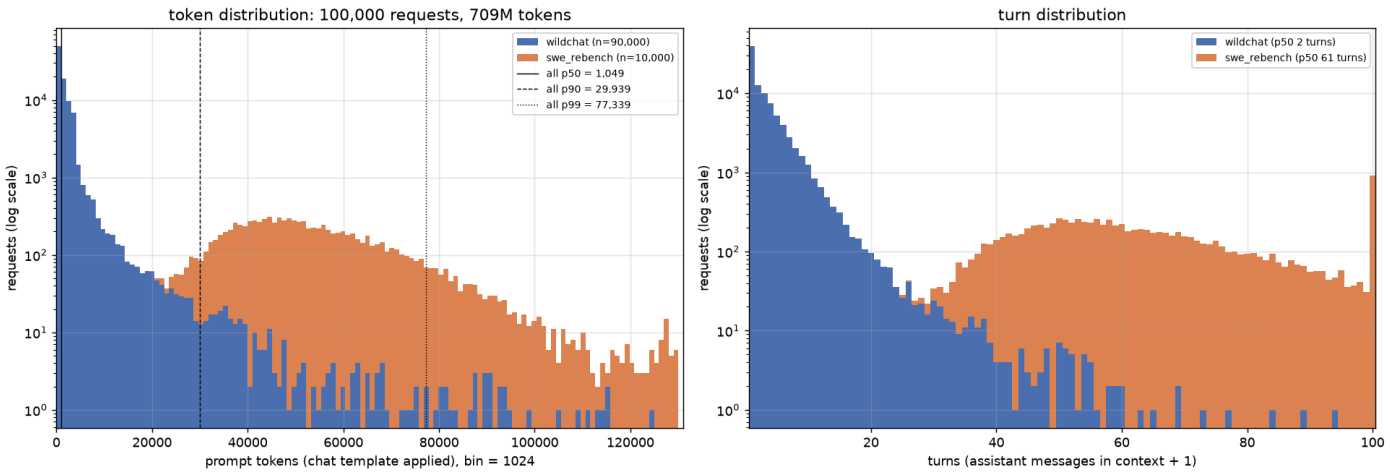
- seed：`20261013`；长度上限 max_input_tokens：131,000；样本指纹：`adb5f129fcad008d`

数据源	原始可用行数	超过长度上限	规则过滤后	抽样条数	抽样 token 数
wildchat	834,359	6	416,829	90,000	165,508,082
swe_rebench	67,074	5	67,069	10,000	543,621,284

数据源	请求数	长度均值	长度 p50	长度 p90	长度 p99	长度最大	轮次均值	轮次 p50	轮次 p90	轮次最大
wildchat	90,000	1,839	893	3,425	15,419	124,484	3	2	7	94
swe_rebench	10,000	54,362	51,242	76,790	109,582	129,940	64	61	97	100
合计	100,000	7,091	1,049	29,939	77,339	129,940	9	2	34	100

各长度区间的请求数，以及在全部请求数、全部 token 数中的占比：

长度区间	wildchat	swe_rebench	合计	请求占比 %	token 占比 %
0-512	10128	0	10128	10.1	0.2
512-1k	39156	0	39156	39.2	4.1
1k-2k	18722	0	18722	18.7	3.9
2k-4k	16475	0	16475	16.5	6.8
4k-8k	3382	0	3382	3.4	2.7
8k-16k	1310	0	1310	1.3	2.1
16k-32k	582	568	1150	1.1	4.2
32k-64k	198	7220	7418	7.4	50.7
64k-128k	47	2212	2259	2.3	25.4



纯 prefill 测试结果（SGLang one_batch，**`ModelRunner.extend`**）

每次 `extend()` 调用前后各做一次 device synchronize 计时，不经过 server、HTTP、调度器，也不做 chunked prefill。

口径说明：多张卡按数据并行各跑一部分请求时，数量类指标（请求数、token 数、耗时）是所有卡的合计，效率类指标（每卡 tok/s、延迟、MFU）是单卡口径。

- 每卡 tok/s（单卡） = token 总数 ÷ extend 总耗时（各卡合计）÷ TP 大小；
- 总吞吐 tok/s（全部卡） = token 总数 ÷ 墙钟时间；
- MFU（单卡） = 理论计算量（线性层 + causal attention）÷ extend 总耗时 ÷（单卡峰值 × TP 大小）；
- 墙钟时间：从第一条请求开始到最后一条结束的实际时间，多卡并行时取整体跨度（生成模式下包含 decode 时间）。

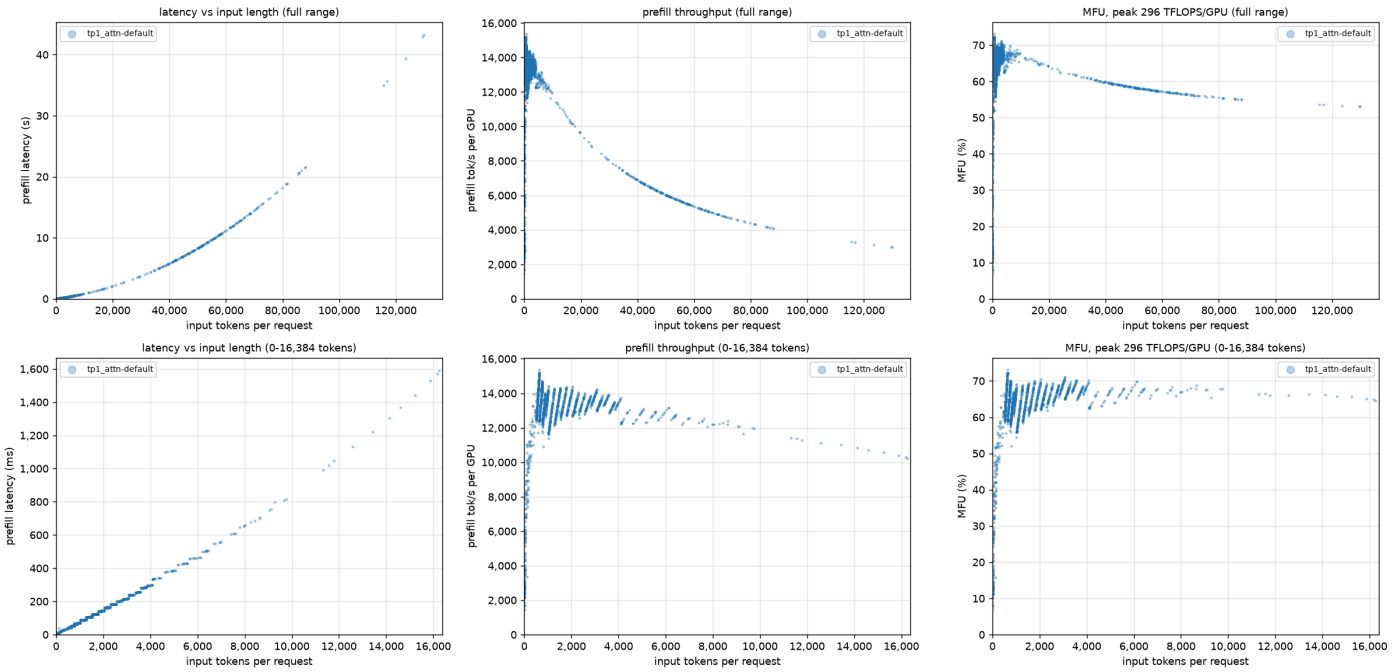
配置	GPU 数	请求数（合计）	extend 次数（合计）	token 总数（合计）	extend 总耗时（合计，GPU·h）	每卡 tok/s（单卡）	墙钟时间 (h)	MFU %（单卡）	GPU 利用率 %（平均）
tp1_attn-default	2	2,002	2,002	14,221,654	0.65	6,080.98	1.22	57.98	93.06

`tp1_attn-default`：按输入长度分段

每条请求单独做一次 extend()，延迟即该请求的纯 prefill 时间（不含任何服务开销的 TTFT）。

输入长度	extend 次数（合计）	平均 token 数	延迟 p50 (ms)	延迟 p90 (ms)	每卡 tok/s（单卡）	MFU %（单卡）
0-512	177	130.5	9.0	27.0	9,068.8	42.8
512-1k	848	742.0	52.4	70.4	13,668.9	65.2
1k-2k	353	1,470.5	106.5	142.0	13,226.0	64.1
2k-4k	321	2,886.4	214.0	282.8	13,398.3	66.9
4k-8k	66	5,630.6	429.9	605.0	12,592.6	66.5
8k-16k	20	11,689.5	1,004.4	1,533.9	11,186.4	66.3
16k-32k	18	23,672.9	2,580.7	3,766.1	8,753.1	62.7
32k-64k	160	49,635.9	8,306.9	11,639.7	5,956.2	58.2
64k-128k	39	80,781.2	15,646.8	35,081.2	4,204.6	55.2

上排为完整长度范围，下排放大 0–16k 区间；两个坐标轴都是线性刻度。



完整生成测试（prefill + decode）

每条请求先做一次 prefill（`extend()`），再用官方 `decode()` 逐个 token 生成到数据中真实回复的长度（忽略 EOS，长度有上限），每一步前后都做 device synchronize。均为单请求（batch size 1）、单卡口径。

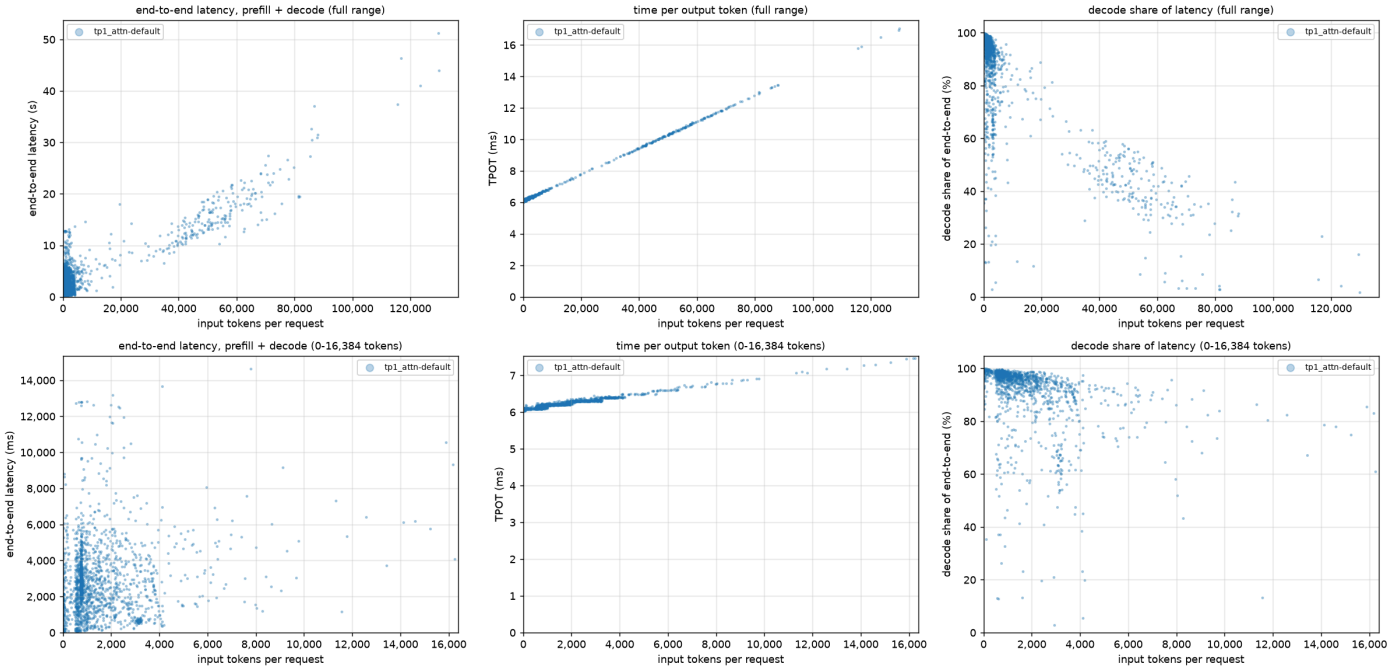
- TTFT：prefill 时间（即首 token 延迟）；
- TPOT：每个输出 token 的 decode 时间（取该请求各步的中位数）；
- 端到端延迟 = TTFT + 全部 decode 步的时间，即生成完整回复所需的时间；
- decode 占比 = decode 时间 ÷ 端到端延迟；每卡 decode tok/s = 输出 token 数 ÷ decode 时间。

配置	请求数（合计）	输出 token 总数（合计）	平均输出长度	TTFT p50 (ms)	TPOT p50 (ms)	端到端 p50 (s)	端到端 p90 (s)	decode 占比 %	每卡 decode tok/s（单卡）
tp1_attn-default	2,002	921,948	460.51	71.27	6.19	2.78	10.88	72.92	146.07

`tp1_attn-default`：按输入长度分段

输入长度	请求数（合计）	平均输入长度	平均输出长度	TTFT p50 (ms)	TPOT p50 (ms)	端到端 p50 (s)	端到端 p90 (s)	decode 占比 %
0-512	177	130.5	361.6	9.0	6.1	1.8	4.9	99.4
512-1k	848	742.0	448.3	52.4	6.1	2.6	4.6	98.1
1k-2k	353	1,470.5	468.7	106.5	6.2	2.5	5.7	96.3
2k-4k	321	2,886.4	408.6	214.0	6.3	2.4	5.2	92.3
4k-8k	66	5,630.6	523.4	429.9	6.6	3.4	6.2	88.5
8k-16k	20	11,689.5	577.0	1,004.4	7.1	5.2	9.2	79.7
16k-32k	18	23,672.9	789.8	2,580.7	8.1	8.4	12.9	70.1
32k-64k	160	49,635.9	633.2	8,306.9	10.3	14.5	19.5	43.8
64k-128k	39	80,781.2	501.8	15,646.8	12.2	23.8	38.1	24.9

上排为完整长度范围，下排放大 0–16k 区间；两个坐标轴都是线性刻度。每个点是一条请求，输出长度为该请求在数据中的真实回复长度。



GPU 利用率

nvidia-smi 采样的 `utilization.gpu`（有 kernel 在运行的时间占比，不等于 SM 占用率）。

