H200 请求形状与并发测试报告

NVIDIA H200

测试日期：2026-10-16；54/54 档；完成请求合计 27,903。

单卡；Qwen3-8B-FP8；decoder block 0–23，共 24 层；context_length=81920；SGLang 0.5.19；PyTorch 2.13.0+cu130；mem_fraction_static=0.75。进程内 Engine 直接提交 token IDs，max_new_tokens=1，prefill 完成即结束。

来源与可比范围

唯一来源运行：shape_20261016_035008_h200

本报告只使用该次完整测试的 summary.jsonl、逐请求 CSV、config.yaml、sampling_config.json、env.txt / serve.log；不混入其他测试或后续 KV 诊断。所有 54 档计算/服务吞吐、命中率和 p90 均已由原始请求 CSV 复算，与原汇总一致。

负载与统计口径

闭环并发：普通形状为 C 个在途请求；分段形状为 C 条轨迹，每条轨迹的四个累积前缀顺序发送。每档至少 60 秒且完成 4×C 请求；达到 900 秒时停止发新请求，再排空在途请求。prefill=4096 同时设置 chunked_prefill_size 和 max_prefill_tokens；default 由引擎解析。

原始窗口吞吐：把每个请求的 token 按其请求生命周期与发请求窗口的重叠比例分摊，再除以窗口时长。完整耗时吞吐：全部完成请求的 token 总数 ÷ 最后一个请求完成时刻（计时从测量阶段 t=0 开始，包含在途排空，不包含引擎加载和预热）。两者均由客户端记录复算，不是引擎内部的逐 token 执行计数。

计算吞吐只计输入减缓存命中后的 token；服务吞吐计全部输入 token。延迟包含客户端提交至完成期间的排队与计算；分段形状的延迟是每段延迟。

每档仅一次运行，无独立重复实验或置信区间；长请求低并发样本较少，分位延迟应作近似参考。结果不代表完整 36 层模型、持续 decode、HTTP 与分词端到端性能，也不能直接推导每瓦或每元性能。

日志记录 DeepGEMM 预热。本次日志未完整记录 resolved attention 后端及 KV token 容量，不以后续诊断值替代。

短请求（约 4k）

吞吐单位 tok/s；延迟单位秒。窗口计算为原报告数值；完整计算 / 完整服务包含排空阶段。缓存命中率按全部完成请求 token 统计。

prefill size = 4096

并发 C	窗口计算	完整计算	完整服务	命中率	p90 秒	请求数
1	79,506	79,506	79,506	0.0%	0.055	1208
2	83,184	83,165	83,165	0.0%	0.108	1262
4	87,245	87,162	87,162	0.0%	0.189	1329
8	87,670	87,479	87,479	0.0%	0.376	1333
16	87,942	87,484	87,484	0.0%	0.751	1344
32	88,460	87,491	87,491	0.0%	1.498	1359
64	89,463	87,415	87,415	0.0%	2.955	1382
128	91,614	87,450	87,450	0.0%	5.856	1454
256	95,865	87,447	87,447	0.0%	11.624	1590

prefill size = default

并发 C	窗口计算	完整计算	完整服务	命中率	p90 秒	请求数
1	79,222	79,223	79,223	0.0%	0.056	1204
2	82,255	82,225	82,225	0.0%	0.102	1248
4	85,668	85,583	85,583	0.0%	0.194	1305
8	89,055	88,902	88,902	0.0%	0.370	1354
16	89,379	88,942	88,942	0.0%	0.739	1366
32	89,881	88,924	88,924	0.0%	1.476	1381
64	90,895	88,865	88,865	0.0%	2.949	1405
128	93,056	88,940	88,940	0.0%	5.717	1476
256	97,358	88,916	88,916	0.0%	11.437	1607

C=256 原窗口吞吐为 95,865，完整耗时吞吐为 87,447。高并发窗口值可能受按生命周期分摊 token 的估算影响，不能直接当作稳定容量。

长请求（约 64k，一次性提交）

吞吐单位 tok/s；延迟单位秒。窗口计算为原报告数值；完整计算 / 完整服务包含排空阶段。缓存命中率按全部完成请求 token 统计。

prefill size = 4096

并发 C	窗口计算	完整计算	完整服务	命中率	p90 秒	请求数
1	30,688	30,720	30,720	0.0%	2.400	29
2	31,562	31,170	31,170	0.0%	4.499	31
4	32,161	30,518	30,518	0.0%	9.290	31
8	34,347	31,250	31,250	0.0%	17.905	40
16	34,477	30,848	30,848	0.0%	34.203	80
32	34,751	31,037	31,037	0.0%	66.836	160

prefill size = default

并发 C	窗口计算	完整计算	完整服务	命中率	p90 秒	请求数
1	30,898	30,920	30,920	0.0%	2.389	29
2	31,802	31,419	31,419	0.0%	4.511	31
4	32,420	30,834	30,834	0.0%	9.140	32
8	34,597	31,524	31,524	0.0%	17.659	40
16	34,737	31,113	31,113	0.0%	33.913	80
32	35,097	31,339	31,339	0.0%	66.165	160

长轨迹分四段，不复用 KV

吞吐单位 tok/s；延迟单位秒。窗口计算为原报告数值；完整计算 / 完整服务包含排空阶段。缓存命中率按全部完成请求 token 统计。

prefill size = 4096

并发 C	窗口计算	完整计算	完整服务	命中率	p90 秒	请求数
1	37,097	37,067	37,067	0.0%	2.013	56
2	37,648	37,447	37,447	0.0%	3.813	57
4	38,393	37,433	37,433	0.0%	7.550	60
8	41,488	37,911	37,911	0.0%	14.641	67
16	39,903	38,496	38,496	0.0%	29.337	80
32	40,542	39,013	39,013	0.0%	56.468	160

prefill size = default

并发 C	窗口计算	完整计算	完整服务	命中率	p90 秒	请求数
1	37,517	37,549	37,549	0.0%	1.980	57
2	37,950	38,052	38,052	0.0%	3.906	59
4	39,080	37,689	37,689	0.0%	7.479	61
8	41,735	38,411	38,411	0.0%	14.293	68
16	40,272	38,889	38,889	0.0%	29.179	80
32	41,195	39,644	39,644	0.0%	55.394	160

长轨迹分四段，复用 KV

吞吐单位 tok/s；延迟单位秒。窗口计算为原报告数值；完整计算 / 完整服务包含排空阶段。缓存命中率按全部完成请求 token 统计。

prefill size = 4096

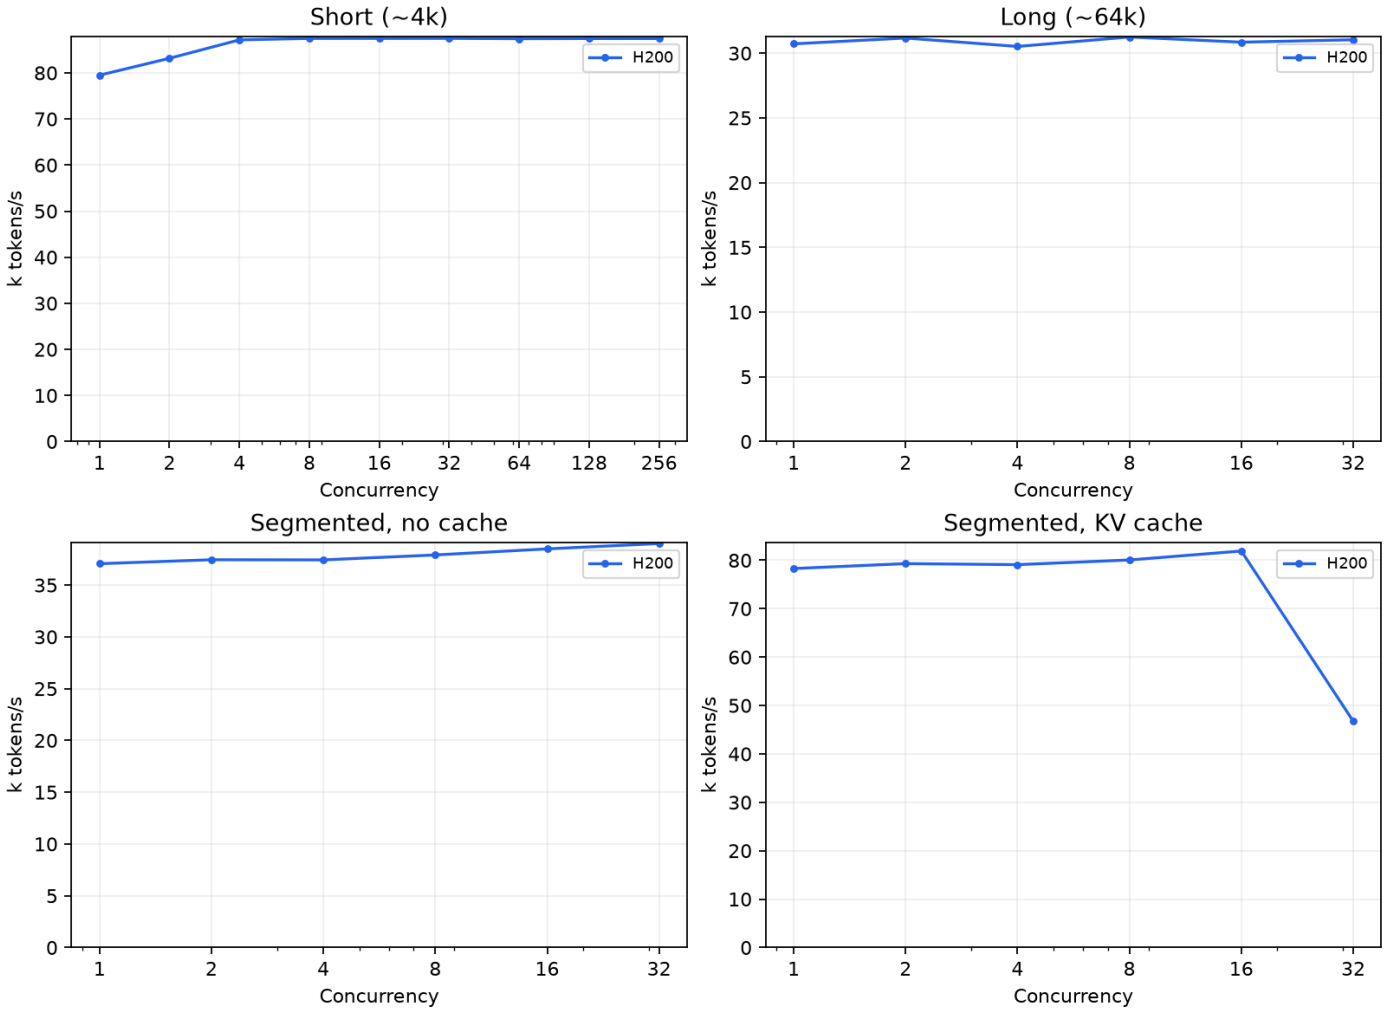
并发 C	窗口计算	完整计算	完整服务	命中率	p90 秒	请求数
1	28,810	28,819	78,293	63.2%	0.842	118
2	29,299	29,022	79,308	63.4%	1.513	120
4	29,834	29,441	79,098	62.8%	2.931	123
8	30,786	29,349	80,064	63.3%	5.860	130
16	31,692	30,692	81,910	62.5%	10.983	141
32	34,553	33,356	46,753	28.7%	56.555	160

prefill size = default

并发 C	窗口计算	完整计算	完整服务	命中率	p90 秒	请求数
1	29,147	29,087	79,403	63.4%	0.832	120
2	29,450	29,197	79,784	63.4%	1.631	120
4	30,117	29,753	79,935	62.8%	2.982	123
8	30,991	29,764	80,951	63.2%	5.864	131
16	31,904	31,004	82,561	62.4%	11.129	142
32	35,090	33,882	47,493	28.7%	55.430	160

固定 4096：C=8 / 16 / 32 命中率分别为 63.3% / 62.5% / 28.7%；完整服务吞吐为 80,064 / 81,910 / 46,753。缓存保留情况改变时应同时看服务吞吐与延迟。

曲线与延迟目标



固定 prefill=4096；完整耗时吞吐。分段缓存面板展示含缓存命中的服务吞吐。

满足 p90 的最大已测并发

0 表示 C=1 也未达标；仅在已测离散档位中选最大值，不代表精确并发极限。

形状	p90 要求	4096 最大 C	default 最大 C
short	⩽ 0.25s	4	4
short	⩽ 0.5s	8	8
short	⩽ 1s	16	16
short	⩽ 2s	32	32
long	⩽ 10s	4	4
long	⩽ 20s	8	8
long	⩽ 30s	8	8
long	⩽ 60s	16	16
long_seg_nocache	⩽ 10s	4	4
long_seg_nocache	⩽ 20s	8	8
long_seg_nocache	⩽ 30s	16	16
long_seg_nocache	⩽ 60s	32	32
long_seg_cache	⩽ 10s	8	8
long_seg_cache	⩽ 20s	16	16
long_seg_cache	⩽ 30s	16	16
long_seg_cache	⩽ 60s	32	32

每档仅一次运行，无独立重复实验或置信区间；长请求低并发样本较少，分位延迟应作近似参考。结果不代表完整 36 层模型、持续 decode、HTTP 与分词端到端性能，也不能直接推导每瓦或每元性能。