Thor 请求形状与并发测试报告

NVIDIA Thor

测试日期：2026-10-19；54/54 档；完成请求合计 7,124。

单卡；Qwen3-8B-FP8；decoder block 0–23，共 24 层；context_length=81920；SGLang 0.5.19；PyTorch 2.13.0+cu130；mem_fraction_static=0.75。进程内 Engine 直接提交 token IDs，max_new_tokens=1，prefill 完成即结束。

来源与可比范围

唯一来源运行：shape_20261019_113407_thor

本报告只使用该次完整测试的 summary.jsonl、逐请求 CSV、config.yaml、sampling_config.json、env.txt / serve.log；不混入其他测试或后续 KV 诊断。所有 54 档计算/服务吞吐、命中率和 p90 均已由原始请求 CSV 复算，与原汇总一致。

负载与统计口径

闭环并发：普通形状为 C 个在途请求；分段形状为 C 条轨迹，每条轨迹的四个累积前缀顺序发送。每档至少 60 秒且完成 4×C 请求；达到 900 秒时停止发新请求，再排空在途请求。prefill=4096 同时设置 chunked_prefill_size 和 max_prefill_tokens；default 由引擎解析。

原始窗口吞吐：把每个请求的 token 按其请求生命周期与发请求窗口的重叠比例分摊，再除以窗口时长。完整耗时吞吐：全部完成请求的 token 总数 ÷ 最后一个请求完成时刻（计时从测量阶段 t=0 开始，包含在途排空，不包含引擎加载和预热）。两者均由客户端记录复算，不是引擎内部的逐 token 执行计数。

计算吞吐只计输入减缓存命中后的 token；服务吞吐计全部输入 token。延迟包含客户端提交至完成期间的排队与计算；分段形状的延迟是每段延迟。

每档仅一次运行，无独立重复实验或置信区间；长请求低并发样本较少，分位延迟应作近似参考。结果不代表完整 36 层模型、持续 decode、HTTP 与分词端到端性能，也不能直接推导每瓦或每元性能。

后端与运行条件

120W 系统功耗模式；约 122.8 GiB 统一内存。FP8 GEMM 使用 Triton，attention 使用 FlashInfer，未进行专门 kernel 调优。固定 4096 档 KV 容量约 87.1–87.3 万 token；默认档 chunk=8192、max_prefill_tokens=16384。模型 revision 固定为 220b46e3b2180893580a4454f21f22d3ebb187d3。

短请求（约 4k）

吞吐单位 tok/s；延迟单位秒。窗口计算为原报告数值；完整计算 / 完整服务包含排空阶段。缓存命中率按全部完成请求 token 统计。

prefill size = 4096

并发 C	窗口计算	完整计算	完整服务	命中率	p90 秒	请求数
1	5,343	5,343	5,343	0.0%	0.829	81
2	5,488	5,456	5,456	0.0%	1.570	84
4	5,595	5,510	5,510	0.0%	2.985	87
8	5,718	5,518	5,518	0.0%	5.958	91
16	5,988	5,519	5,519	0.0%	11.913	100
32	6,162	5,508	5,508	0.0%	23.826	160
64	6,181	5,514	5,514	0.0%	46.085	320
128	6,190	5,513	5,513	0.0%	92.144	640
256	6,188	5,511	5,511	0.0%	185.201	1280

prefill size = default

并发 C	窗口计算	完整计算	完整服务	命中率	p90 秒	请求数
1	5,288	5,288	5,288	0.0%	0.846	80
2	5,377	5,344	5,344	0.0%	1.634	82
4	5,550	5,473	5,473	0.0%	3.105	86
8	5,693	5,531	5,531	0.0%	5.937	92
16	5,969	5,535	5,535	0.0%	11.869	100
32	6,160	5,526	5,526	0.0%	23.745	160
64	6,191	5,533	5,533	0.0%	45.931	320
128	6,205	5,532	5,532	0.0%	91.848	641
256	6,207	5,530	5,530	0.0%	185.276	1281

C=256 原窗口吞吐为 6,188，完整耗时吞吐为 5,511。高并发窗口值可能受按生命周期分摊 token 的估算影响，不能直接当作稳定容量。

长请求（约 64k，一次性提交）

吞吐单位 tok/s；延迟单位秒。窗口计算为原报告数值；完整计算 / 完整服务包含排空阶段。缓存命中率按全部完成请求 token 统计。

prefill size = 4096

并发 C	窗口计算	完整计算	完整服务	命中率	p90 秒	请求数
1	1,990	2,016	2,016	0.0%	34.258	5
2	2,081	1,964	1,964	0.0%	72.805	10
4	2,146	1,992	1,992	0.0%	136.939	20
8	2,236	1,985	1,985	0.0%	267.966	35
16	2,503	1,966	1,966	0.0%	538.784	43
32	3,115	1,991	1,991	0.0%	1055.525	60

prefill size = default

并发 C	窗口计算	完整计算	完整服务	命中率	p90 秒	请求数
1	2,008	2,033	2,033	0.0%	33.934	5
2	2,099	1,984	1,984	0.0%	71.153	10
4	2,166	2,011	2,011	0.0%	135.911	20
8	2,250	2,002	2,002	0.0%	265.580	36
16	2,519	1,982	1,982	0.0%	534.492	43
32	3,133	2,005	2,005	0.0%	1046.949	60

长轨迹分四段，不复用 KV

吞吐单位 tok/s；延迟单位秒。窗口计算为原报告数值；完整计算 / 完整服务包含排空阶段。缓存命中率按全部完成请求 token 统计。

prefill size = 4096

并发 C	窗口计算	完整计算	完整服务	命中率	p90 秒	请求数
1	2,182	2,264	2,264	0.0%	35.135	5
2	2,448	2,446	2,446	0.0%	53.755	10
4	2,513	2,466	2,466	0.0%	109.792	20
8	2,570	2,492	2,492	0.0%	221.456	40
16	2,860	2,388	2,388	0.0%	475.710	72
32	3,736	2,459	2,459	0.0%	763.351	116

prefill size = default

并发 C	窗口计算	完整计算	完整服务	命中率	p90 秒	请求数
1	2,201	2,278	2,278	0.0%	34.821	5
2	2,475	2,471	2,471	0.0%	53.264	10
4	2,536	2,495	2,495	0.0%	108.437	20
8	2,595	2,520	2,520	0.0%	217.806	40
16	2,872	2,412	2,412	0.0%	471.615	72
32	3,752	2,478	2,478	0.0%	757.578	116

长轨迹分四段，复用 KV

吞吐单位 tok/s；延迟单位秒。窗口计算为原报告数值；完整计算 / 完整服务包含排空阶段。缓存命中率按全部完成请求 token 统计。

prefill size = 4096

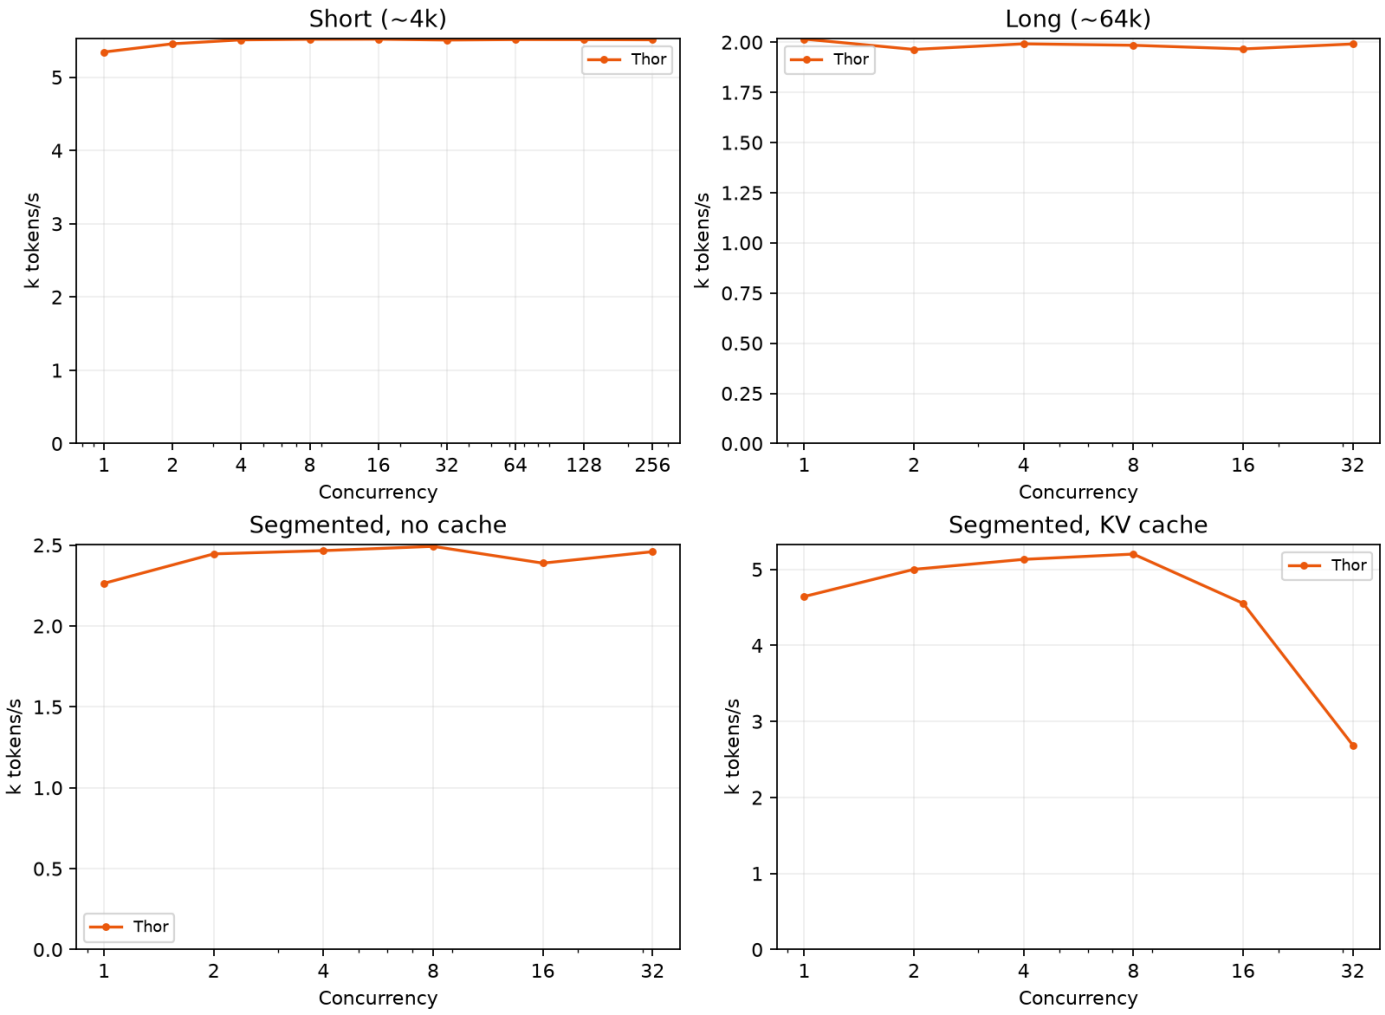
并发 C	窗口计算	完整计算	完整服务	命中率	p90 秒	请求数
1	1,930	1,919	4,643	58.7%	13.567	7
2	2,009	2,039	5,000	59.2%	22.641	10
4	2,051	2,026	5,132	60.5%	44.818	20
8	2,102	2,037	5,201	60.8%	87.527	40
16	2,076	1,985	4,553	56.4%	211.627	80
32	3,209	2,096	2,688	22.0%	851.891	126

prefill size = default

并发 C	窗口计算	完整计算	完整服务	命中率	p90 秒	请求数
1	1,944	1,936	4,686	58.7%	13.453	7
2	1,993	2,050	5,027	59.2%	21.987	10
4	2,059	2,046	5,183	60.5%	44.498	20
8	2,120	2,063	5,269	60.8%	87.167	40
16	2,091	2,003	4,601	56.5%	206.518	80
32	3,232	2,118	2,716	22.0%	841.238	126

固定 4096：C=8 / 16 / 32 命中率分别为 60.8% / 56.4% / 22.0%；完整服务吞吐为 5,201 / 4,553 / 2,688。缓存保留情况改变时应同时看服务吞吐与延迟。

曲线与延迟目标



固定 prefill=4096；完整耗时吞吐。分段缓存面板展示含缓存命中的服务吞吐。

满足 p90 的最大已测并发

0 表示 C=1 也未达标；仅在已测离散档位中选最大值，不代表精确并发极限。

形状	p90 要求	4096 最大 C	default 最大 C
short	⩽ 0.25s	0	0
short	⩽ 0.5s	0	0
short	⩽ 1s	1	1
short	⩽ 2s	2	2
long	⩽ 10s	0	0
long	⩽ 20s	0	0
long	⩽ 30s	0	0
long	⩽ 60s	1	1
long_seg_nocache	⩽ 10s	0	0
long_seg_nocache	⩽ 20s	0	0
long_seg_nocache	⩽ 30s	0	0
long_seg_nocache	⩽ 60s	2	2
long_seg_cache	⩽ 10s	0	0
long_seg_cache	⩽ 20s	1	1
long_seg_cache	⩽ 30s	2	2
long_seg_cache	⩽ 60s	4	4

每档仅一次运行，无独立重复实验或置信区间；长请求低并发样本较少，分位延迟应作近似参考。结果不代表完整 36 层模型、持续 decode、HTTP 与分词端到端性能，也不能直接推导每瓦或每元性能。